

Paralelizácia databázových dotazov v aplikácii MedSavant

Miroslav Cupák

Diplomová práca

10. 2. 2014

Problém

- aplikácia: vyhľadávač nad genetickými variáciami (MedSavant)
 - problém: jednovláknové spracovanie dotazov v databáze (Infobright Community Edition)
 - riešenie: paralelizácia spracovania databázových dotazov na úrovni aplikácie (sharding)
 - cieľ: vyšší výkon a škálovateľnosť
-
- spolupráca: Centre for Computational Medicine (SickKids Research Institute) a Computational Biology Lab (University of Toronto)

MedSavant

MedSavant

File View Help

Project Variants Clinic Admin

App Store root

Spreadsheet Search Bar Inspector

Browser

Charts

6.252 (0.5%)
of all variants pass search conditions

Chromosome is chr1
and Position is > 24,361,714
and OMIM is OMIM:ANGELMAN SYNDROME

Type search condition

Search

Type to search page

More Fields

DNA ID	...	Position	V...	...
KB_174_26528	chr1	26,127,020	G	A	61.5	SNP	Hom...	
KB_174_26528	chr1	26,127,202	T	G	176	SNP	Hom...	
KB_174_26528	chr1	26,127,203	T	C	165	SNP	Hom...	
KB_174_26528	chr1	26,127,425	G	A	176	SNP	Hetero	
KB_174_26528	chr1	26,129,430	G	T	30	SNP	Hetero	
KB_174_26528	chr1	26,131,459	G	A	144	SNP	Hetero	
KB_174_26528	chr1	26,131,654	G	A	222	SNP	Hom...	
KB_174_26528	chr1	26,133,099	A	G	62	SNP	Hom...	
KB_174_26528	chr1	26,134,833	T	C	69.5	SNP	Hom...	
KB_174_26528	chr1	26,134,926	C	G	147	SNP	Hetero	
KB_174_26528	chr1	26,135,741	C	G	114	SNP	Hetero	
KB_174_26528	chr1	26,135,913	T	C	84.3	SNP	Hom...	
KB_174_26528	chr1	26,136,452	A	C	222	SNP	Hom...	
KB_174_26528	chr1	26,138,136	C	A	222	SNP	Hom...	
KB_174_26528	chr1	26,138,262	T	C	222	SNP	Hom...	
KB_174_26528	chr1	26,138,451	A	G	71.5	SNP	Hom...	
KB_174_26528	chr1	26,139,055	(too l...	(too l...	176	SNP	Hom...	
KB_174_26528	chr1	26,139,137	C	T	222	SNP	Hom...	
KB_174_26528	chr1	26,139,392	A	G	147	SNP	Hom...	
KB_174_26528	chr1	26,139,444	G	A	111	SNP	Hom...	
KB_174_26528	chr1	26,139,679	C	G	131	SNP	Hom...	
KB_174_26528	chr1	26,139,919	C	T	163	SNP	Hom...	
KB_174_26528	chr1	26,140,573	C	A	222	SNP	Hom...	
KB_174_26528	chr1	26,141,803	G	T	99.5	SNP	Hom...	
KB_174_26528	chr1	27,121,921	C	A	49	SNP	Hetero	
KB_174_26528	chr1	27,124,545	A	G	40	SNP	Hetero	
KB_174_26528	chr1	27,238,150	A	G	78	SNP	Hetero	
KB_174_26528	chr1	33,252,099	(too l...	TCAC...	182	Delet...	Hetero	
KB_174_26528	chr1	33,252,687	T	C	76.5	SNP	Hom...	
KB_174_26528	chr1	33,256,884	C	A	225	SNP	Hetero	
KB_174_26528	chr1	33,275,981	T	C	137	SNP	Hetero	
KB_174_26528	chr1	33,276,424	G	A	222	SNP	Hom...	

Showing 1 - 500 of 6,252

Page 1 of 13

Per page: 500

Variant Gene

Basic Variant Information

POSITION chr1:26,127,202

REFERENCE T

ALTERNATE G

TYPE SNP

GENES SEPNI 18.0 kbp

Detailed Variant Information

DNA ID KB_174_26528

ZYGOSITY HomoAlt

QUALITY 176

DBSNP ID NULL

REF SHOW

Comments

Submit

Individuals with a variant at this position

KB_174_170258

KB_174_26528

KB_174_10-462

MedSavant

MedSavant

File View Help

Project Variants Clinic Admin

App Store root

Spreadsheet Search Bar Genome Variation

Browser

Charts

6,252 (0.5%)
of all variants pass search conditions

Chromosome is chr1

and Position is > 24,361,714

and OMIM is OMIM:ANGELMAN SYNDROME

Type search condition

Search

Location chr1: 26,127,182 - 26,127,223 Go Length: 42

chr1:26127182-26127223

Allele Frequency Table

Name	Type	Position	Ref	Alt
SNP		261272...	T	G
SNP		261272...	T	C

LD Plot

Map

http://genomesavant.com/savant/data/hg19/hg19.fa.savant

http://genomesavant.com/savant/data/hg19/hg19.refGene.gz

SEPNI

SEPNI

Filtered Variants

Tools Display Mode Appearance

ymax=5

KB_174_PHS1-1

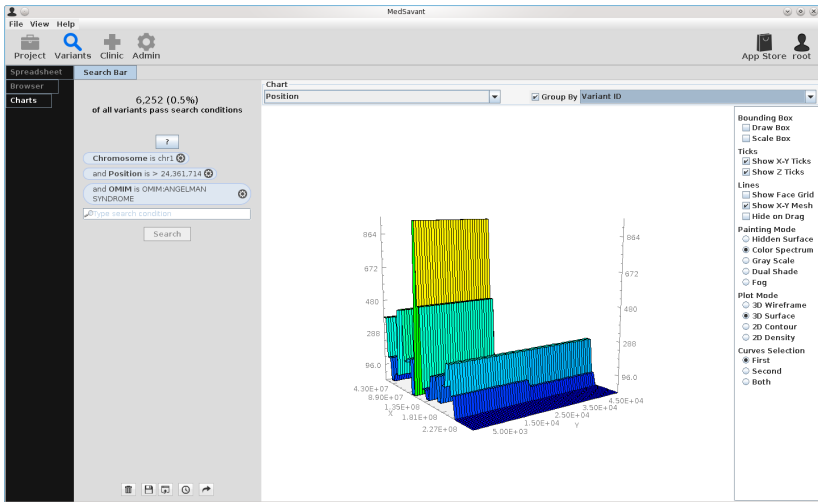
KB_174_B1272

KB_174_26528

KB_174_170258

KB_174_10462

MedSavant



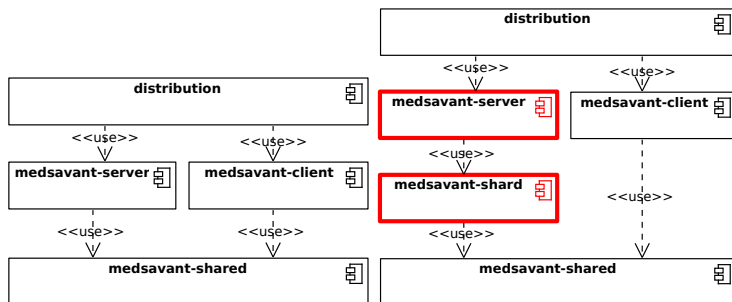
Sharding

- z angl. rozlomenie, rozbitie
- SHAReD-nothING architektúra
- horizontálne rozdelenie množiny dát na nezávislé servery
- distribúcia dotazov a agregácia výsledkov
- sharding stratégia

Požiadavky

- vyšší výkon pri spracovaní pomalých dotazov
- lepšia škálovateľnosť
- plná podpora ICE
- využitie viacerých výpočetných jednotiek zariadenia
- podpora dát rozložených na distribuované servery
- integrácia so serverom
- objektovo orientovaný prístup
- jednoduchá migrácia
- dobre merateľný a reprodukovateľný výkon

Modul



- 2 časti
 - všeobecný sharding rámec
 - sharding logika špecifická pre MedSavant

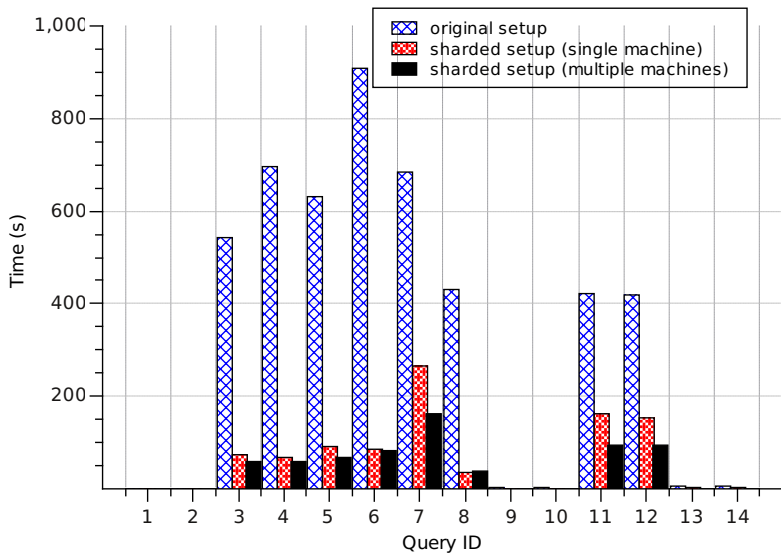
Spracovanie dotazov

- čítanie/zápis
 - rovnaký dotaz na všetky uzly/dotaz pre konkrétny uzol
 - 1 logická databáza/prístup ku konkrétnym uzlom
- fázy spracovania dotazu
 - vygenerovanie pôvodného dotazu v SQL
 - transformácia dotazu do distribuovaného prostredia
 - zaslanie dotazu na databázové servery
 - prijatie čiastkových výsledkov a ich agregácia
 - úprava výsledkov pre potreby aplikácie
- 2 sharding stratégie založené na pozícii v chromozóme
- ďalšie úlohy
 - správa spojení, konfigurácia, udržovanie mapovania...


Merania

- 2 aspekty
 - zlepšenie výkonu
 - úspech sharding stratégie
- 2 databázy
 - DB_1 : 134 958 340 variácií
 - DB_2 : 1 378 423 987 variácií
- 2 konfigurácie
 - C_1 : žiadna paralelizácia (1 databáza, pôvodná implementácia)
 - C_2 : paralelizácia v rámci 1 stroja (1 server, 8 shards)
 - C_3 : paralelizácia v distribuovanom prostredí (8 serverov, 8 shards)
- 14 základných dotazov (Q_1 - Q_{14})

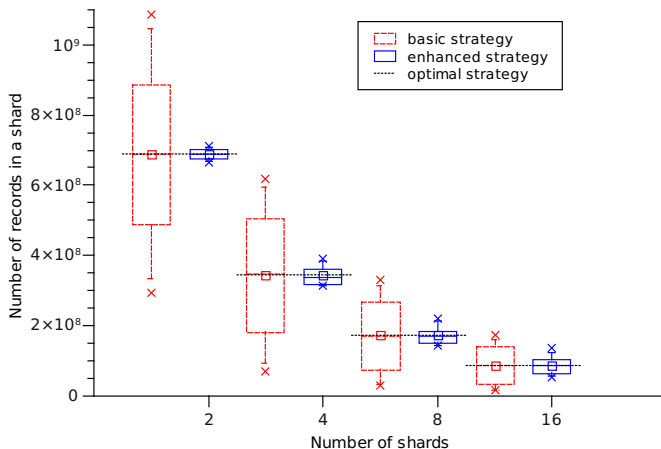
Čas spracovania (DB_2)



Zrýchlenie (DB_2)



Distribúcia dát (DB_2)



- relatívna smerodajná odchýlka **65.44+%**, resp. **4.71+%**

Zhrnutie

- vytvorenie sharding rámca, návrh sharding stratégie pre genetické dáta, plná integrácia s MedSavant
- riešenie spĺňa všetky požiadavky, predovšetkým:
 - vyšší výkon pri spracovaní pomalých dotazov (75+%)
 - dobrá škálovateľnosť (lineárna až superlineárna)
- od odovzdania práce:
 - spätná väzba od CCM
 - demo tento týždeň
 - plány na zaradenie funkcionality do produktu
 - vedecký článok
 - súvisiaci projekt: *sharding in the cloud*

Ďakujem.
Otázky?